LANDSCAPE CLASSIFICATION

Progetto per l'esame di Introduction to Deep Learning

Mattia Toffolo, 820438

Vasile Cerchez, 796850

Francesco Galimberti, 829315

ABSTRACT

L'efficacia delle deep convolutional neural network è affermata nel campo del riconoscimento di immagini rappresentanti oggetti convenzionali, però non è ancora ampiamente dimostrata dalla comunità scientifica la sua utilità su immagini relative a paesaggi. In questo nostro lavoro abbiamo sviluppato diverse topologie di reti convoluzionali con lo scopo di classificare 6 categorie di paesaggi: Edifici, Foreste, Ghiacciai, Mare, Montagne e Strade. Sono state utilizzate varie tipologie di rete e di tecniche per trattare l'overfitting giungendo infine alla conclusione che la rete migliore, la quale fornisce un accuracy leggermente superiore al 90%, si ottiene sfruttando la tecnica di fine tuning sulla rete pre-allenata vgg19. Risulta quindi evidente che la possibilità di lavorare con reti allenate su milioni di immagini porti a considerabili vantaggi in problemi di questa tipologia.

INTRODUZIONE

Nella recente esplosione dei Big Data e del Machine Learning le reti neurali hanno giocato un ruolo fondamentale. Esse trovano diverse tipologie di applicazione in svariati campi. In particolare, per quanto riguarda l'analisi di dati non strutturati (ad esempio le immagini), le reti neurali convoluzionali sono ampiamente utilizzate.

Nel campo della geomorfologia, la classificazione di immagini di paesaggi acquisite tramite satelliti, velivoli, veicoli aerei senza pilota e telecamere fisse ha una funzione essenziale. Questa tipologia di analisi può avere risvolti molto complessi quanto importanti, quali la valutazione di cambiamenti nell'ambiente, la quantificazione della vegetazione e il calcolo della granulometria del suolo. L'efficacia generale delle deep convolutional neural network è nota per quanto riguarda il riconoscimento di immagini rappresentanti oggetti convenzionali, mentre la sua utilità non è ancora ampiamente dimostrata dalla comunità scientifica su scala paesaggistica. La differenza principale è che le immagini dei paesaggi sono riprese da un punto di vista elevato (hanno una prospettiva verticale/obliqua), mentre le immagini con oggetti/volti sono prese da vicino ed hanno una prospettiva orizzontale. Inoltre, le variazioni di luminosità e di contrasto dovute alle diverse stagioni influiscono sulla distribuzione del colore e rendono più difficile il riconoscimento di pattern.

In questo progetto si propone un problema multiclasse di riconoscimento immagini che rappresentano diversi paesaggi naturali e antropici. Questo progetto è motivato dalla curiosità circa l'ambito applicativo ancora non esplorato del tutto e i tool innovativi. L'obiettivo finale è costruire una rete neurale convoluzionale che classifichi nuove immagini con modalità incognita con una precisione sufficientemente soddisfacente.

MATERIALI E METODI

1) Materiali

Il dataset in esame è composto da immagini suddivise in sei classi: Edifici, Foreste, Ghiacciai, Mare, Montagne e Strade. Esso contiene 14043 immagini totali nell'insieme di addestramento (training set) e 3000 immagini totali nell'insieme di verifica (test set).

Per simulare una situazione reale, l'errore di generalizzazione sarà valutato su un validation set e infine la performance finale della rete verrà calcolata su un test set, di cui teoricamente non si conosce la classe delle immagini. Dunque, l'insieme di addestramento originale è stato suddiviso in un ulteriore training set di numerosità inferiore (1750 immagini per classe, cioè il 75% del training set di partenza) ed in un validation set (585 immagini per classe, cioè il 25% del training set di partenza). Le dimensioni finali delle cartelle sono di 10528 immagini per il training set, 3506 immagini per il validation set e 3000 immagini per il test set.

Il dataset è bilanciato, cioè le diverse classi sono presenti circa nella medesima proporzione in ogni set di dati.

La dimensione di una singola immagine è 150x150 (x3, rgb).

Il dataset è stato scaricato dalla piattaforma online Kaggle.

2) Metodi

Per lo svolgimento del progetto ci siamo concentrati sulle reti neurali convoluzionali a discapito delle reti neurali classiche in quanto, le prime imparano patterns locali mentre le seconde acquisiscono caratteristiche globali. Le convolutional neural network sono maggiormente funzionali nel nostro contesto applicativo.

Prima di procedere con l'addestramento delle reti vi è la fase di pre-processing. Le immagini del dataset sono in formato .jpg, esse devono essere trasformate in tensori 3D per essere utilizzate come input nella rete. La preparazione avviene attraverso i seguenti passaggi:

1. Leggere i file delle immagini.

2. Trasformare le immagini da JPG a RGB (griglia di pixels).

3. Convertire il risultato in tensori di tipo floating che saranno usati come input nella rete.

4. Riscalare i pixel (valori compresi tra [1, 256]) a valori in un intervallo tra [0, 1].

5. Successivamente le immagini sono state divise come precedentemente spiegato in training e validation set.

Allo scopo di raggiungere l'obiettivo dell'analisi sono state implementate più reti neurali convoluzionali diverse tra loro, in modo da avere un ventaglio di scelte per il modello definitivo. In generale, tutte le reti seguiranno una struttura classica che consiste nel succedersi di convolutional layers e pooling layers (Max pooling). Gli ultimi strati seguono una struttura FFNN (Feed Forward Neural Network) ed operano la classificazione delle osservazioni. Data la natura multiclasse del task di classificazione, l'ultimo strato è caratterizzato da una funzione di attivazione softmax.

La prima rete neurale utilizzata presenta un'architettura molto semplice, infatti è formata da 3 layer convoluzionali e 2 layer di max pooling alternati, oltre agli ultimi 2 strati finali densi. Questo modello è servito da benchmark: la sua accuracy sarà di riferimento e aiuterà a capire se, per reti piu' complesse, il guadagno in termini di performance previsiva è significativo oppure se si sta solo aumentando la profondità delle reti e conseguentemente il peso computazionale con un aumento non sostanzioso dell'accuracy.

La seconda rete consiste in un completamento della prima con ulteriori 2 strati convoluzionali ed uno di max pooling. Dato che quest'ultima rete presenta un evidente problema di overfitting si è deciso di utilizzare 2 metodi differenti per provare a mitigare questo sovradattamento.

Il primo metodo consiste nell'applicazione di due layer di dropout caratterizzati da un rate pari a 0.5 alla seconda rete già addestrata in precedenza. Il secondo, applicato alla quarta rete neurale considerata per questo studio, è il metodo della data augmentation; una tecnica che consiste nell'aumentare la numerosità del dataset in maniera artificiale e solitamente viene applicata con dataset piccoli oppure quando, come nel nostro caso, c'è un'esplicita presenza di overfitting.

L'idea della data augmentation si basa sul fatto che con infinite immagini, la rete sarebbe in grado di catturare tutte le caratteristiche "speciali" di ogni classe e di conseguenza dovrebbe prevedere in modo perfetto. Per questo si cerca di aumentare l'ampiezza del dataset in modo artificiale, applicando delle trasformazioni casuali come traslazioni dell'immagine verso destra o verso sinistra, zoommando o ruotando. Queste nuove immagini saranno usate nel training set per permettere alla rete di osservare più immagini, estrarre più informazioni e garantire risultati più robusti.

Le trasformazioni fatte con i rispettivi parametri nella miglior configurazione trovata sono state le seguenti:

```
train_datagen <-image_data_generator(
  rescale = 1/255,
  rotation_range=15,
  width_shift_range = 0.2,
  height_shift_range = 0.2,
  shear_range = 0.2,
  zoom_range = 0.2,
  #horizontal_flip = TRUE,
  validation_split = 0.25  )
```

La scelta dei migliori parametri è stata fatta in base a ragionamenti logici e in base a prove empiriche. Per esempio, la rete preforma peggio se rotation_range assume un valore alto oppure horizontal_flip=T perché sono trasformazioni che non sono molto adatte a questo tipo di immagini in cui solitamente l'immagine ha un orientamento corretto (difficilmente si trova un'immagine di una montagna ruotata di 90 gradi).

Questa tecnica è stata implementata sia sulla seconda che sulla terza rete, ovvero la data augmentation è stata valutata sia singolarmente che in combinazione con dei layer di dropout.

Data l'ottima capacità previsiva delle reti pre-allenate come sesta ed ultima rete considerata abbiamo provato a sfruttare il metodo del *fine tuning*.

Il *fine tuning* consiste nella procedura di aggiustamento dei pesi dei layer più profondi di una rete pre-allenata. Nel nostro lavoro ne sono state valutate alcune e si è scelto di utilizzare quella che portasse a risultati migliori, ovvero l'architettura *vgg19*.

Essa è composta da 5 blocchi di layer, ed ogni blocco è costituito da alcuni layer convoluzionali e da un ultimo layer di max pooling, i primi due blocchi contengono 3 layer, gli ultimi 3 ne contengono 5.

Layer (type)	Output Shape	Param #
input_2 (InputLayer)	[(None, 150, 150, 3)]	0
block1_conv1 (Conv2D)	(None, 150, 150, 64)	1792
block1_conv2 (Conv2D)	(None, 150, 150, 64)	36928
block1_pool (MaxPooling2D)	(None, 75, 75, 64)	0
block2_conv1 (Conv2D)	(None, 75, 75, 128)	73856
block2_conv2 (Conv2D)	(None, 75, 75, 128)	147584
block2_pool (MaxPooling2D)	(None, 37, 37, 128)	0
block3_conv1 (Conv2D)	(None, 37, 37, 256)	295168
block3_conv2 (Conv2D)	(None, 37, 37, 256)	590080
block3_conv3 (Conv2D)	(None, 37, 37, 256)	590080
block3_conv4 (Conv2D)	(None, 37, 37, 256)	590080
block3_pool (MaxPooling2D)	(None, 18, 18, 256)	0
block4_conv1 (Conv2D)	(None, 18, 18, 512)	1180160
block4_conv2 (Conv2D)	(None, 18, 18, 512)	2359808
block4_conv3 (Conv2D)	(None, 18, 18, 512)	2359808
block4_conv4 (Conv2D)	(None, 18, 18, 512)	2359808
block4_pool (MaxPooling2D)	(None, 9, 9, 512)	0
block5_conv1 (Conv2D)	(None, 9, 9, 512)	2359808
block5_conv2 (Conv2D)	(None, 9, 9, 512)	2359808
block5_conv3 (Conv2D)	(None, 9, 9, 512)	2359808
block5_conv4 (Conv2D)	(None, 9, 9, 512)	2359808
block5_pool (MaxPooling2D)	(None, 4, 4, 512)	0

Total params: 20,024,384
Trainable params: 20,024,384
Non-trainable params: 0

I pesi della rete *vgg19* sono stati ottenuti allenandola sul dataset *ImageNet*, il quale contiene più di 14 milioni di immagini divise in oltre 1000 classi.

Per aggiustare i pesi si procede "scongelando" gli strati più profondi, la rete con prestazioni migliori è risultata essere quella ottenuta scongelando i pesi dal primo layer convoluzionale del quarto blocco (*block4_conv1*), successivamente si allena la rete con le nostre immagini di training. Alla rete pre-allenata inizialmente sono stati aggiunti degli strati fully connected poi, per migliorare le prestazioni della rete, si è deciso di aggiungere anche un layer di dropout. Per evitare di avere grandi cambiamenti della rete il learning rate è stato scelto basso, ovvero pari a 10^{-5}.

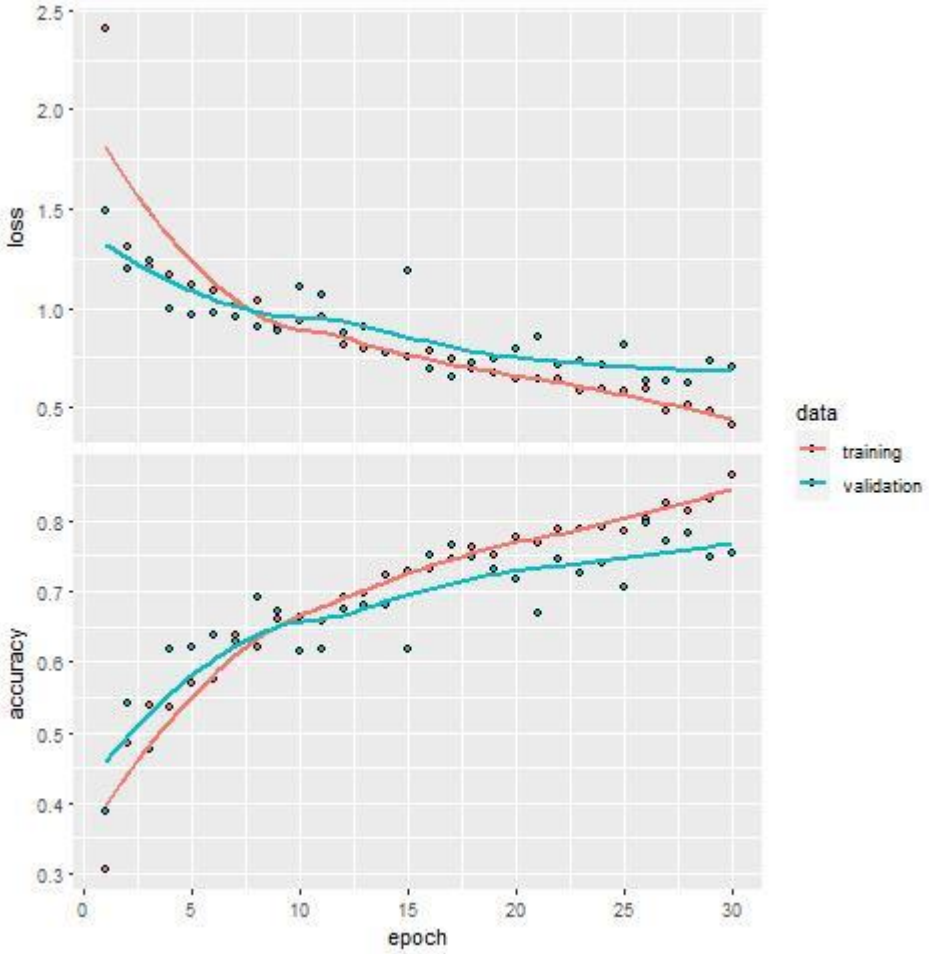
RISULTATI

Nella seguente tabella sono riportati i valori di accuracy ottenuti da ogni modello sul test set.

RETE	TEST ACCURACY
Rete benchmark	75,93 %
Rete più complessa	81,88 %
Rete con dropout	85,50 %
Rete con data augmentation	75,60 %
Rete con dropout e data augmentation	72,77 %
Rete pre-allenata	91,10 %

1) Rete benchmark

La prima rete è stata utilizzata per avere un risultato benchmark con cui confrontare gli altri, infatti l'obiettivo del nostro lavoro è stato quello di migliorare i risultati ottenuti di volta in volta partendo da questa rete.

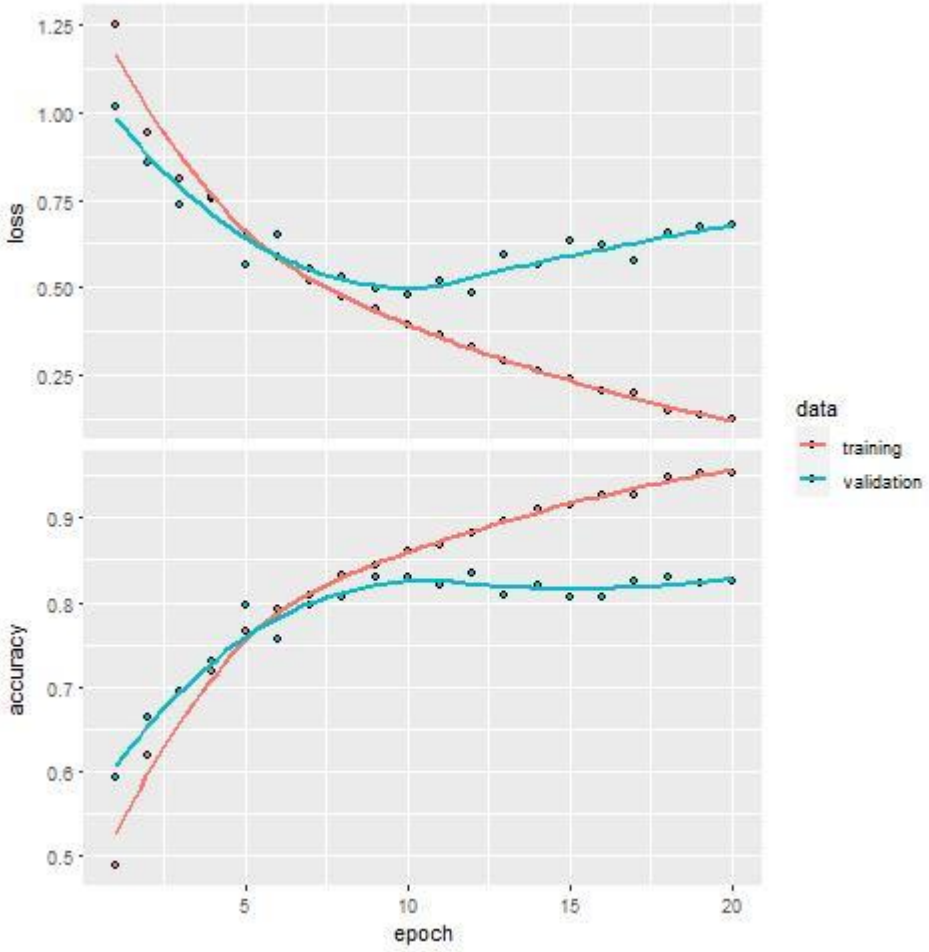


Nell'immagine qui sopra si può notare come la rete presenti un leggero fenomeno di overfitting; i valori di accuracy nel training sono significativamente maggiori rispetto a quelli nel validation set dalla decima epoca in poi. Inoltre, l'accuracy ottenuta valutando questa rete sulle immagini del test set non è per particolarmente elevata, risulta essere pari a 75,93%. La rete, mediamente, compie un errore ogni 4 classificazioni. Tuttavia, la rete rappresenta comunque un miglioramento rispetto ad un classificatore

completamente casuale, il quale assegnerebbe la classe corretta con probabilità 1/6 (cioè circa con il 16,6% di accuracy).

2) Rete più complessa

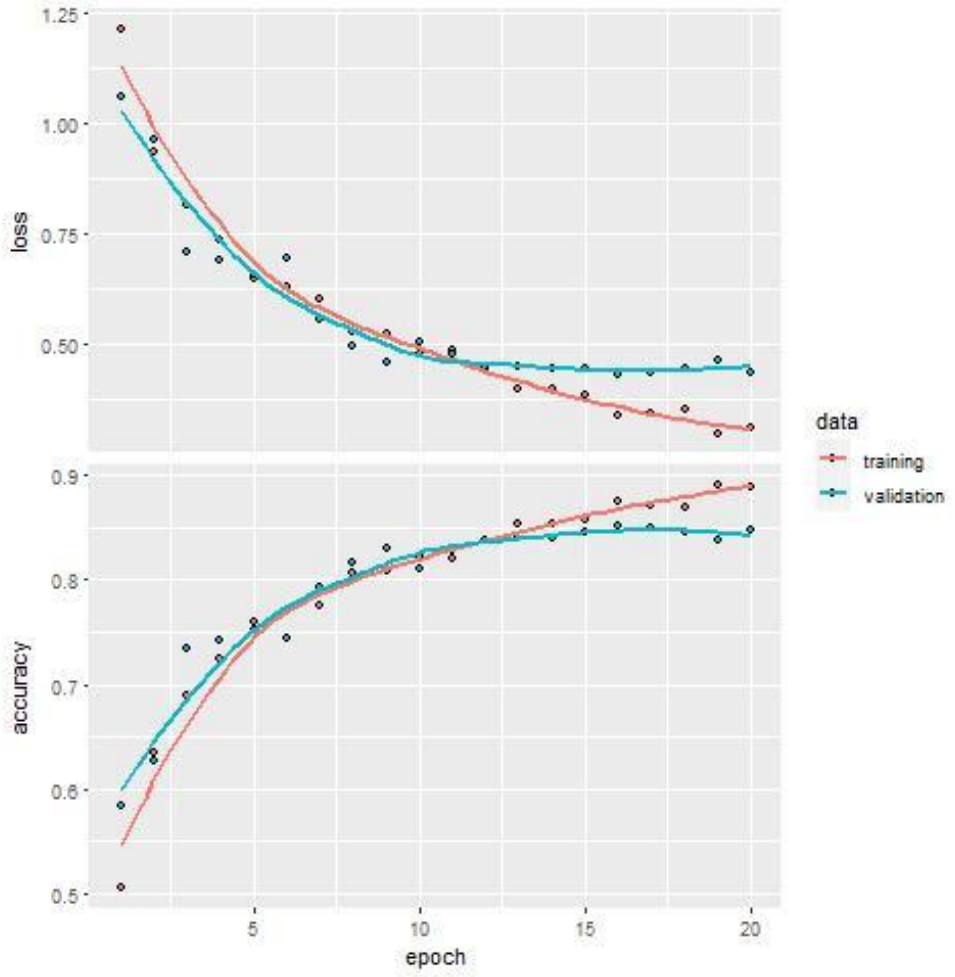
Successivamente si è testata una rete più complessa in termini di numero di layer impiegati.



Come si può notare dal grafico, complicando la rete, si è ottenuto un incremento significativo per quanto riguarda il livello di accuracy. Il prezzo da pagare per questo miglioramento è legato alla presenza di un maggiore overfitting. La distanza tra le curve relative al training set e quelle relative al validation set aumenta al crescere delle epoche. Questo algoritmo funziona molto bene sui dati di training, ma quando la si utilizza su dei dati non ancora visti le sue performance calano drasticamente. Sul test set si registra comunque un punteggio di accuracy aumentato di circa 6 punti percentuali rispetto alla rete precedente.

3) Rete con dropout

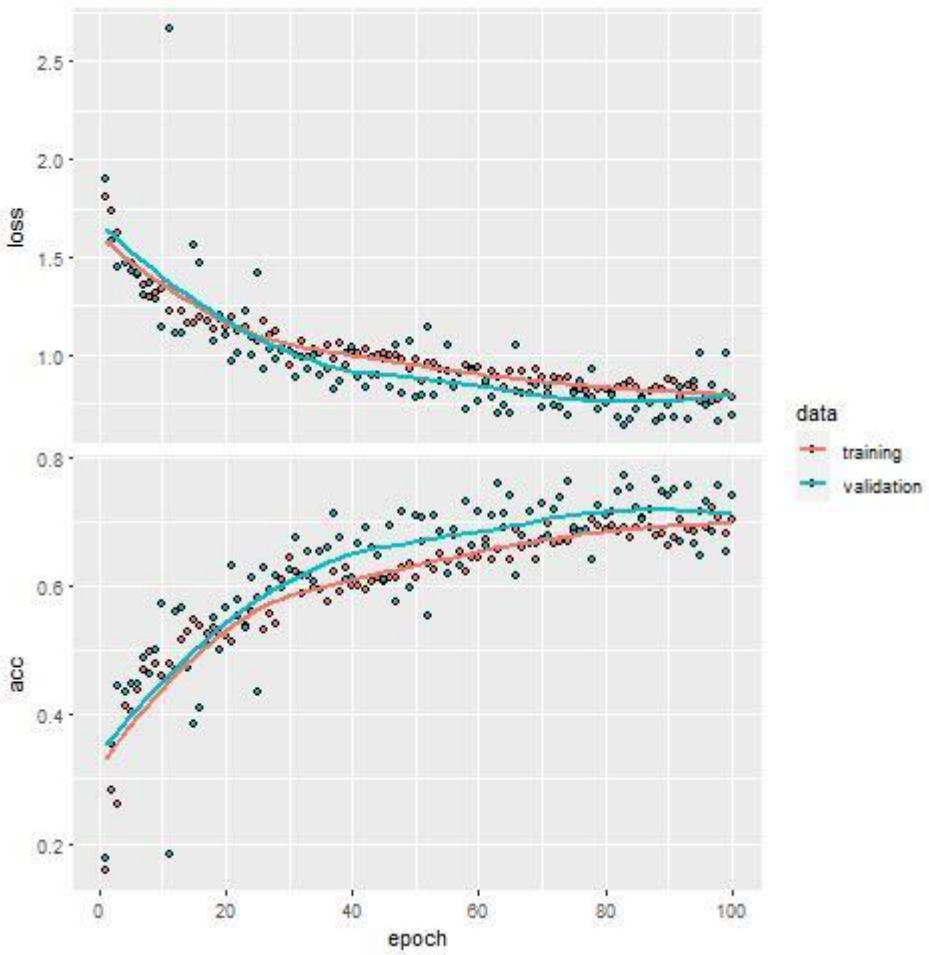
Con lo scopo di ridurre il sovradattamento riscontrato sono stati aggiunti 2 layer di dropout, entrambi con un rate pari a 0.5 (ovvero 50%).



Come emerge dal grafico l'overfitting è stato limitato. Oltre a ciò, i layer di dropout hanno comportato un aumento della precisione del modello; l'acccuracy ottenuta sulle immagini del test set è pari al 85,50%, il che significa che le immagini classificate correttamente sono state più di 5 ogni 6.

4) Rete con data augmentation

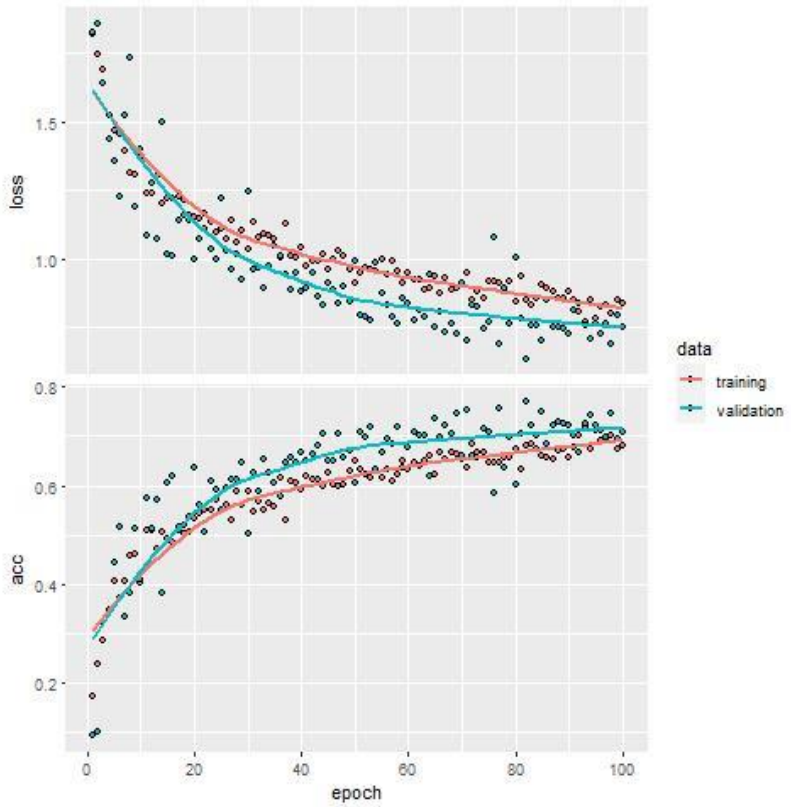
Il secondo metodo utilizzato per affrontare l'overfitting è la data augmentation. La rete ottenuta dopo aver applicato la data augmentation sulle immagini del training set ha certamente ottenuto il risultato di risolvere l'overfitting, come si può notare nell'immagine sottostante. Le due curve non si separano nemmeno dopo 100 epoche, cioè non vi è una sostanziosa differenza tra le performance previsive del modello sui dati di training e sui dati di validation. Tuttavia va sottolineato che il valore assoluto dell'accuracy è diminuito rispetto agli algoritmi precedenti.



L'accuracy ottenuta sul test set è pari al 75,60 %, più bassa di quella trovata con il modello benchmark di partenza. Abbiamo provato a capire le motivazioni di questo notevole peggioramento, una possibile interpretazione è la seguente; la data augmentation porta grandi miglioramenti soprattutto quando le immagini del training sono molto simili tra loro. Controllando a campione le immagini a nostra disposizione, abbiamo notato come esse siano molto diverse, per esempio per quanto riguarda la classe "*montagna"* si possono trovare foto scattate da diverse angolature e di montagne molto diverse tra loto; alcune sono innevate altre no, alcune includono strade altre no, altre ancora comprendono laghi e/o persone e così via. Le unità statistiche del dataset sono molto eterogenee e già differenziate.

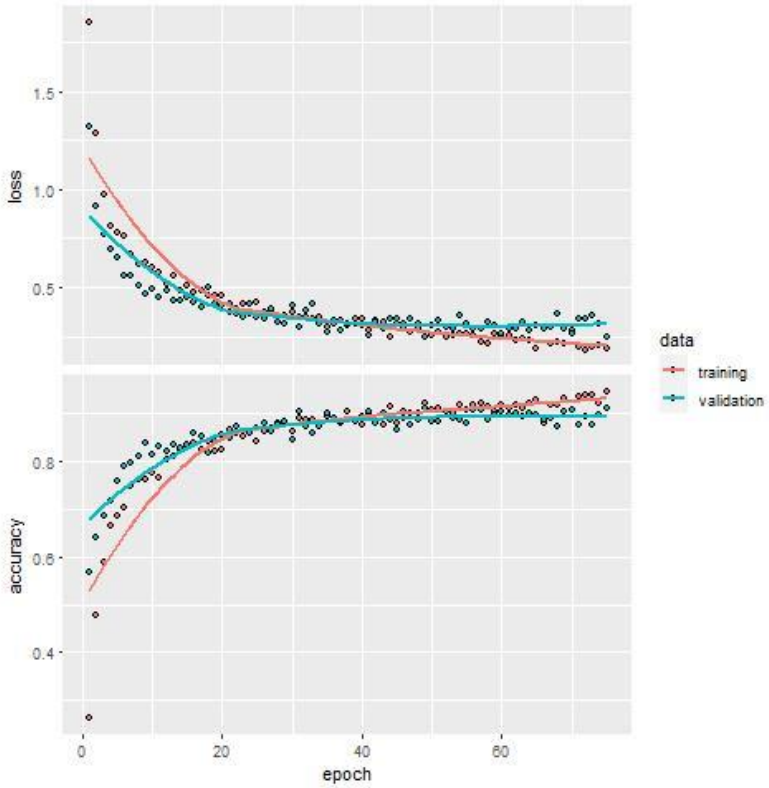
5) Rete con dropout e data augmentation

La quinta rete è caratterizzata dalla combinazione di entrambi i metodi "anti-overfitting" testati in precedenza singolarmente. Si è ottenuto un ulteriore peggioramento per quanto riguarda la precisione della reta, l'accuracy risulta essere del 72.77% sul test set. L'overfitting risulta comunque essere controllato.



6) Rete pre-allenata

Infine, è stata utilizzata una rete pre-allenata. I risultati ottenuti sono notevolmente migliori; l'accuracy sul test set ha raggiunto il valore 91.10% e non risulta verificarsi alcun fenomeno di sovradattamento dei dati in maniera esplicita come in precedenza. L'overfitting potrebbe eventualmente presentarsi in questo contesto qualora decidessimo di incrementare ulteriormente il numero di epoche.



Questa rete ha ottenuto quindi la migliore prestazione e non ha riportato problemi riguardanti l'overfitting. Il suo unico svantaggio risiede nello sforzo computazionale richiesto, infatti, come si può notare dalla tabella sottostante, i parametri da "allenare" sono quasi 20 milioni.

Layer (type)	Output Shape	Param #	Trainable
vgg19 (Functional)	(None, 4, 4, 512)	20024384	Y
flatten_1 (Flatten)	(None, 8192)	0	Y
dropout_1 (Dropout)	(None, 8192)	0	Y
dense_3 (Dense)	(None, 256)	2097408	Y
dense_2 (Dense)	(None, 6)	1542	Y

Total params: 22,123,334
Trainable params: 19,797,766
Non-trainable params: 2,325,568

CONCLUSIONI

In questa parte si discuteranno le ipotesi fatte prima di iniziare il progetto, le problematiche, i risultati e i possibili sviluppi futuri.

Le conclusioni, che coincidono con le ipotesi fatte prima di iniziare il progetto e con numerosi risultati ottenuti in letteratura, ci dicono che la rete pre-allenata è quella con le performance migliori, che richiede uno sforzo computazionale diverso e che può essere applicata in diversi contesti problematici (es. un dataset piccolo e/o con classi sbilanciate). Utilizzando una rete pre-allenata abbiamo potuto ottenere un evidente miglioramento in termini di accuracy sia sul validation set sia sul test set senza andare in overfitting, cosa che accade molto frequentemente con una rete classica più complessa. Per cercare di evitare questo fenomeno abbiamo applicato il dropout che ha portato un miglioramento dei risultati. Il grande limite di questo lavoro riguarda non solo la mancanza di un miglioramento delle reti con data augmentation, ma addirittura un peggioramento dei risultati. In questo caso l'overfitting viene risolto però rimane comportamento da indagare e molto controintuitivo. Una possibile soluzione potrebbe consistere nell'usare la data augmentation ma con reti molto più complesse.

L'utilizzo della classificazione delle immagini può essere applicato e viene già applicato molto frequentemente tutti i giorni. Basta pensare a un motore di ricerca oppure un'agenzia di viaggi che vuole sapere i luoghi preferiti per trascorrere le vacanze.

Sviluppi futuri del lavoro potrebbero essere provare ad aggiungere più classi oppure utilizzare un classificatore binario in grado di dire se nella foto ci sono più paesaggi diversi contemporaneamente, in quanto la presenza di una classe non esclude l'altra; ci possono essere immagini che contengono sia palazzi sia strade, sia montagna sia mare. Inoltre potrebbe essere interessante analizzare se per i modelli è molto più difficile classificare alcune classi rispetto ad altre e concentrarsi su quelle classi maggiormente ostiche (ad esempio è ragionevole supporre che i ghiacciai possano essere classificati come montagna e viceversa). Altri possibili sviluppi potrebbero essere l'utilizzo di reti pre-allenate più complesse e andare a sfruttare il lavoro di altri ricercatori senza partire da zero, oppure sfruttare l'ensemble learning combinando più reti neurali semplici e complesse ma diverse tra loro.

BIBLIOGRAFIA

Chollet, Allaire (2018) Deep Learning with R. Manning

D.Buscombe, A.C. Ritchie, Landscape Classification with Deep Neural Networks

Simonyan, Karen and Zisserman, Andrew, Very Deep Convolutional Networks for Large-Scale Image Recognition

SITOGRAFIA

https://www.kaggle.com/datasets/puneet6060/intel-image-classification